TRƯỜNG ĐẠI HỌC THỦ DẦU MỘT · CHUYÊN NGÀNH HỆ THỐNG THÔNG TIN

Mười thuật toán dự đoán năng lực học tập học sinh lớp 9

Nó là gì · Ưu nhược điểm · Cách hoạt động trên dữ liệu của luận văn · Lập luận lựa chọn

Tài liệu kỹ thuật kèm luận văn "Khung học sâu tích hợp cơ chế giải thích dự đoán năng lực học tập học sinh cuối cấp THCS"

Dữ liệu: 12 sổ điểm (học kỳ I, học kỳ II, cả năm) của một khóa học sinh Trường THCS Phú An, lớp 6 (2022–2023) → lớp 9 (2025–2026)
Số liệu thực nghiệm trên lưới 7 học kỳ, lấy từ `reports/BAO_CAO_KET_QUA.md` (15 lần chạy cho mỗi mô hình)
Tháng 10 năm 2026

Mục lục

1. Bài toán, dữ liệu và cách đánh giá chung (đọc trước để hiểu phần "cách hoạt động trên dữ liệu của mình")
2. Mười thuật toán, mỗi thuật toán trả lời ba câu hỏi: là gì – ưu nhược điểm – hoạt động thế nào trên dữ liệu của mình
    1. Hồi quy tuyến tính (Ridge) – mốc so sánh
    2. XGBoost – mốc so sánh dạng cây
    3. MLP – mạng truyền thẳng
    4. Bi-LSTM – mạng hồi quy hai chiều
    5. TabNet – chú ý tuần tự chọn đặc trưng
    6. FT-Transformer – Transformer cho dữ liệu bảng
    7. TabPFN – mô hình nền tảng cho dữ liệu bảng
    8. TabKANet – nhúng đặc trưng bằng KAN + Transformer
    9. Kanformer – chú ý đa đầu + lớp KAN
    10. XEdu-KANFormer – khung đề xuất
3. Bảng kết quả tổng hợp và kiểm định thống kê
4. Phương pháp luận: lập luận dẫn đến thuật toán được chọn, tại sao chọn, khắc phục điểm yếu nào, vượt trội ở đâu, và cách trình bày trung thực trước hội đồng
5. Tài liệu tham khảo

1. Bài toán, dữ liệu và cách đánh giá chung

1.1. Dữ liệu

Bộ dữ liệu là sổ điểm tổng kết của **một khóa học sinh** Trường THCS Phú An, theo dõi dọc bốn năm: lớp 6 (2022–2023), lớp 7 (2023–2024), lớp 8 (2024–2025), lớp 9 (2025–2026). Có 613 học sinh xuất hiện ít nhất một năm, 449 em có đủ bốn năm. Dữ liệu gồm 12 sổ điểm: học kỳ I, học kỳ II và cả năm của mỗi lớp. Ở mỗi kỳ, mỗi học sinh có điểm trung bình của 8 môn đánh giá bằng điểm số (Toán, Ngữ văn, Tiếng Anh, Khoa học tự nhiên, Lịch sử và Địa lí, Giáo dục công dân, Công nghệ, Tin học), kết quả rèn luyện, số buổi nghỉ có phép và không phép, và mức kết quả học tập theo Thông tư 22/2021 (Tốt, Khá, Đạt, Chưa đạt). Khóa này không có học sinh ở mức Chưa đạt. Dữ liệu được ẩn danh (mã học sinh băm một chiều; họ tên, số định danh, ngày sinh bị tách khỏi tập huấn luyện).

1.2. Biểu diễn chung cho mọi thuật toán

Mỗi học sinh được biểu diễn thành một **lưới 11 hàng × 7 cột**: 11 hàng gồm 8 môn + kết quả rèn luyện + nghỉ có phép + nghỉ không phép; 7 cột là 7 học kỳ liên tiếp từ học kỳ I lớp 6 đến học kỳ I lớp 9 (thời điểm dự báo). Ô thiếu (học sinh chuyển đến muộn) được đánh dấu bằng **mặt nạ**, không điền giá trị giả. Đầu ra cần dự đoán là **8 điểm trung bình cả năm lớp 9** (hồi quy đa đầu ra) và **mức kết quả học tập lớp 9** (phân mức).

Hàng \ Cột	HK1·6	HK2·6	HK1·7	HK2·7	HK1·8	HK2·8	HK1·9
8 môn	điểm	điểm	điểm	điểm	điểm	điểm	điểm
Rèn luyện	0–3	0–3	0–3	0–3	0–3	0–3	0–3
Nghỉ P / K	log	log	log	log	log	log	log
→ Mục tiêu	**8 điểm cả năm lớp 9 + mức kết quả học tập cả năm lớp 9**						

Để có nhiều mẫu hơn, mô hình được học thêm các **cửa sổ** "HK1 lớp 6 → HK1 lớp 7, dự đoán cả năm lớp 7" và "HK1 lớp 6 → HK1 lớp 8, dự đoán cả năm lớp 8" (các cột tương lai bị che bằng mặt nạ). Tổng cộng 1.531 cửa sổ huấn luyện (519 + 510 + 502); **chỉ 502 cửa sổ có mục tiêu cả năm lớp 9 được dùng để đánh giá**. Các thuật toán dạng "bảng phẳng" (hồi quy tuyến tính, XGBoost, TabNet, TabPFN) nhận lưới này sau khi trải phẳng thành 77 giá trị + 77 cờ mặt nạ + 1 đặc trưng lớp mục tiêu = 155 cột. Các thuật toán học sâu còn lại nhận trực tiếp các ô lưới dưới dạng **token**.

1.3. Cách đánh giá (giống nhau cho cả 10 thuật toán)

- **Chia tập:** kiểm định chéo 5 lần theo lớp học (GroupKFold) × 3 hạt giống = 15 lần chạy. Mọi cửa sổ của một học sinh luôn ở cùng một phần, không rò rỉ. Trong mỗi lần: 70% học sinh để huấn luyện, 15% để dừng sớm, 15% để hiệu chỉnh khoảng dự đoán.
- **Chỉ số:** RMSE và MAE (trung bình 8 môn, và riêng 3 môn thi Toán – Văn – Anh), R^2, Macro-F1 và Acc của phân mức, PICP (độ phủ thực tế) và MPIW (độ rộng) của khoảng dự đoán 90%.
- **Khoảng dự đoán:** mọi mô hình đều được bọc *split conformal* 90% theo từng môn, nên có thể so sánh độ phủ công bằng.
- **Kiểm định:** Friedman trên 120 khối (15 lần chạy × 8 môn), hậu kiểm Nemenyi, Wilcoxon từng cặp trên sai số của từng học sinh.
- **Siêu tham số:** mỗi mô hình dùng một cấu hình cố định hợp lý (ghi ở mục "cách hoạt động"), chưa dò tìm; đây là giới hạn chung, không thiên vị mô hình nào.

Cách đọc các con số

Thang điểm 10. RMSE 0,63 nghĩa là sai số bình phương trung bình tương đương 0,63 điểm; MAE 0,48 nghĩa là trung bình mô hình lệch 0,48 điểm so với điểm thật cả năm lớp 9. Khi chỉ có sổ cả năm (3 mốc lớp 6, 7, 8), sai số của mọi mô hình cao hơn rõ (mô hình tốt nhất RMSE 0,626 so với 0,444 khi có 7 học kỳ) – dữ liệu học kỳ là nguồn cải thiện lớn nhất. Chênh lệch giữa các mô hình học sâu chỉ vài phần trăm điểm, nên **phải dựa vào kiểm định thống kê** chứ không chỉ nhìn thứ hạng.

2. Mười thuật toán

2.1. Hồi quy tuyến tính có điều chuẩn (Ridge) – mốc so sánh

Nó là gì, dùng để làm gì

Hồi quy tuyến tính giả định điểm lớp 9 của một môn là **tổng có trọng số** của các điểm đầu vào: $\hat{y} = w_0 + w_1x_1 + \ldots + w_nx_n$. Ridge thêm phạt L2 lên trọng số để tránh nhiễu khi các đầu vào tương quan mạnh (điểm các môn thường tương quan 0,6–0,85). Phân mức dùng hồi quy logistic. Trong luận văn nó là **mốc dưới**: mọi thuật toán phức tạp hơn phải chứng minh mình vượt mốc này một cách có ý nghĩa thống kê.

Ưu điểm và nhược điểm

- **Ưu:** huấn luyện tức thì (0,05 giây), hoàn toàn minh bạch (mỗi trọng số là mức đóng góp của một ô điểm), ổn định với dữ liệu nhỏ, không có siêu tham số đáng kể.
- **Nhược:** chỉ mô hình hóa quan hệ tuyến tính; không nắm được tương tác (ví dụ Toán lớp 8 thấp *và* KHTN giảm); coi lưới môn × năm là một vector phẳng; không có cơ chế xử lý ô khuyết ngoài cờ mặt nạ.

Cách hoạt động trên dữ liệu của mình

Đầu vào 155 cột đã chuẩn hóa; 8 bộ hồi quy Ridge ($\alpha = 1$) cho 8 môn, 1 bộ hồi quy logistic cho mức. Kết quả: RMSE 0,700 ± 0,054, MAE 0,528, R^2 0,781, Macro-F1 0,772, PICP 0,919, MPIW 2,24. Đây là mô hình **kém nhất** về sai số (hạng trung bình 8,65/10) và khung đề xuất tốt hơn nó có ý nghĩa thống kê (Wilcoxon $p = 0,005$). Dù vậy, chỉ một mô hình tuyến tính đã giải thích được 78% phương sai điểm lớp 9 – điểm các học kỳ trước, đặc biệt học kỳ I lớp 9, mang rất nhiều thông tin. Macro-F1 phân mức (0,772) cũng không thấp, vì mức kết quả học tập theo Thông tư 22 gần như là một hàm ngưỡng của điểm.

2.2. XGBoost – mốc so sánh dạng cây

Nó là gì, dùng để làm gì

XGBoost là *gradient boosting* trên cây quyết định: xây tuần tự hàng trăm cây nông, cây sau sửa phần dư của các cây trước. Nó là "đối thủ khó vượt" trên dữ liệu bảng thông thường (Grinsztajn và cs. [34]) và là lựa chọn phổ biến trong các nghiên cứu dự đoán kết quả học tập kết hợp SHAP (Huang và cs. [12]). Đề cương chỉ xếp nó vào nhóm tham chiếu, nhưng thực nghiệm vẫn chạy để có mốc so sánh công bằng.

Ưu điểm và nhược điểm

- **Ưu:** xử lý phi tuyến và tương tác đặc trưng tự nhiên; chịu được ô khuyết; ít nhạy với chuẩn hóa; huấn luyện nhanh (2,5 giây); có SHAP để giải thích hậu nghiệm.
- **Nhược:** coi dữ liệu là bảng phẳng, không biết "Toán lớp 7" và "Toán lớp 8" là cùng một môn qua thời gian; đầu ra đa môn phải huấn luyện độc lập nên không chia sẻ tri thức giữa các môn; dễ quá khớp với ~1.000 mẫu nếu cây sâu; giải thích chỉ hậu nghiệm.

Cách hoạt động trên dữ liệu của mình

400 cây, độ sâu 3, tốc độ học 0,05, lấy mẫu 80% hàng và cột; một bộ hồi quy đa đầu ra và một bộ phân loại trên 155 cột phẳng. Kết quả: **RMSE 0,552 ± 0,040 – hạng 2**, MAE 0,412, R^2 0,863, Macro-F1 0,788, PICP 0,917, MPIW 1,83; chỉ mất 2,3 giây mỗi lần. So với khi chỉ có sổ cả năm (RMSE 0,692, hạng 8), XGBoost là mô hình hưởng lợi nhiều nhất từ dữ liệu học kỳ: cây quyết định chọn rất nhanh cột "học kỳ I lớp 9" – mốc gần mục tiêu nhất. Kết quả này xác nhận nhận định của Grinsztajn và cs. [34] rằng mô hình cây là đối thủ khó vượt trên dữ liệu bảng, và là mốc so sánh bắt buộc phải nêu trong luận văn.

2.3. MLP – mạng nơ-ron truyền thẳng

Nó là gì, dùng để làm gì

MLP (multilayer perceptron) là mạng nơ-ron cơ bản: vector đầu vào đi qua vài lớp ẩn có hàm kích hoạt phi tuyến (ReLU) rồi ra đầu ra. Nó học được quan hệ phi tuyến bất kỳ nếu đủ dữ liệu, và là mô hình học sâu "đơn giản nhất" mà mọi kiến trúc phức tạp hơn phải vượt qua. Trong tổng quan, Pham và cs. [26] dùng MLP cho học sinh THPT Việt Nam.

Ưu điểm và nhược điểm

- **Ưu:** rất nhanh (2,5 giây), ít tham số, dễ huấn luyện đa nhiệm (một mạng ra cả 8 điểm và mức), ổn định với dữ liệu nhỏ khi có dừng sớm và dropout.
- **Nhược:** hộp đen; không có cấu trúc – lưới môn × năm bị trải phẳng, mạng phải tự "khám phá" lại rằng các ô cùng hàng là cùng môn; giải thích chỉ hậu nghiệm.

Cách hoạt động trên dữ liệu của mình

Đầu vào 155 cột → 2 lớp ẩn 64 nơ-ron ReLU, dropout 0,1 → hai đầu ra: hồi quy 8 môn (mất mát Huber) và phân mức 4 lớp (entropy chéo, trọng số $\lambda = 0{,}3$). AdamW, tốc độ học $2 \cdot 10^{-3}$, dừng sớm theo tập 15%. Kết quả: RMSE 0,605 ± 0,045, MAE 0,452, R^2 0,836, Macro-F1 0,810, PICP 0,924. **Hạng 3/10** (hạng trung bình 4,30), không khác XGBoost có ý nghĩa theo Nemenyi (chênh hạng 1,07 < CD 1,24), và nhanh nhất trong nhóm học sâu (1,9 giây). Với khoảng 1.500 cửa sổ, một mạng nhỏ được điều chuẩn tốt đã là đối thủ rất mạnh.

2.4. Bi-LSTM – mạng hồi quy hai chiều

Nó là gì, dùng để làm gì

LSTM là mạng hồi quy có cổng nhớ, đọc một chuỗi token từng bước và giữ trạng thái; Bi-LSTM đọc theo cả hai chiều rồi ghép trạng thái cuối. Nó được dùng rộng rãi để dự đoán kết quả học tập từ dữ liệu theo thời gian (Waheed và cs. [17]; Kalita và cs. [18] đạt 88,23% với Bi-LSTM + SHAP).

Ưu điểm và nhược điểm

- **Ưu:** mô hình hóa được phụ thuộc theo chuỗi; ít tham số hơn Transformer; nhanh (3,8 giây).
- **Nhược:** chỉ xử lý chuỗi **một chiều**, trong khi dữ liệu của mình là lưới **hai chiều** (môn × học kỳ) – phải trải phẳng thành chuỗi 78 token theo một thứ tự tùy ý, các ô cùng môn ở các học kỳ khác nhau nằm xa nhau trong chuỗi; trạng thái ẩn khó diễn giải.

Cách hoạt động trên dữ liệu của mình

78 token (77 ô lưới + 1 đặc trưng tĩnh), mỗi ô nhúng tuyến tính thành vector 32 chiều, ô khuyết dùng token mặt nạ học được; Bi-LSTM ẩn 32 mỗi chiều; ghép hai trạng thái cuối (64) → hai đầu ra đa nhiệm. Kết quả: RMSE 0,644 ± 0,033, MAE 0,488, R^2 0,814, Macro-F1 0,811, PICP 0,923. Hạng 7/10. Chuỗi 78 token trải phẳng cả hai chiều môn × học kỳ làm LSTM khó nhớ các ô cùng môn ở xa nhau; khung đề xuất ngang Bi-LSTM về sai số (Wilcoxon p = 0,49).

2.5. TabNet – chú ý tuần tự chọn đặc trưng

Nó là gì, dùng để làm gì

TabNet (Arik & Pfister [33]) mô phỏng cách cây quyết định chọn đặc trưng: qua nhiều bước, một mặt nạ chú ý thưa (sparsemax) chọn một tập đặc trưng để xử lý, rồi cộng dồn kết quả. Mặt nạ này cho biết mô hình "nhìn vào" cột nào, nên TabNet được giới thiệu là mạng học sâu *có thể diễn giải* cho dữ liệu bảng; Yang và cs. [30] kết hợp nó với siêu đồ thị cho dự đoán học tập.

Ưu điểm và nhược điểm

- **Ưu:** chọn đặc trưng ngay trong mô hình, có mặt nạ chú ý để giải thích; không cần chuẩn hóa phức tạp.
- **Nhược:** nhiều siêu tham số nhạy (n_d, n_a, số bước, γ, batch ảo); nổi tiếng **bất ổn với dữ liệu nhỏ**; huấn luyện chậm nhất trong nhóm (99,7 giây/lần); hồi quy và phân mức phải tách thành hai mô hình riêng nên không đa nhiệm.

Cách hoạt động trên dữ liệu của mình

n_d = n_a = 16, 3 bước, tốc độ học $2 \cdot 10^{-2}$, batch ảo 64, dừng sớm kiên nhẫn 40; TabNetRegressor đa đầu ra + TabNetClassifier trên 155 cột. Kết quả: RMSE 0,671 ± **0,094** (độ lệch chuẩn lớn nhất – rất bất ổn giữa các lần chạy), MAE 0,487, R^2 0,792, **Macro-F1 thấp nhất 0,745**, PICP 0,927. Hạng 9/10; không khác khung đề xuất có ý nghĩa (p = 0,60). Thời gian 74,9 giây mỗi lần. Cơ chế chọn đặc trưng thưa không phát huy khi phần lớn 155 cột đều có ích.

2.6. FT-Transformer – Transformer cho dữ liệu bảng

Nó là gì, dùng để làm gì

FT-Transformer (Gorishniy và cs. [6]) biến **mỗi đặc trưng** thành một token (Feature Tokenizer: x·w + b), thêm token [CLS], rồi cho qua các khối Transformer để self-attention học tương tác giữa các đặc trưng; [CLS] cuối cùng đi vào đầu dự đoán. Đây là kiến trúc Transformer tiêu chuẩn cho dữ liệu bảng, nền tảng của nhiều mô hình sau này.

Ưu điểm và nhược điểm

- **Ưu:** self-attention cho phép mọi ô điểm "nhìn" mọi ô khác, học tương tác liên môn một cách tự nhiên; trọng số chú ý là một nguồn giải thích; mở rộng được khi thêm đặc trưng.
- **Nhược:** tốn tham số hơn MLP, cần nhiều dữ liệu hơn; coi 33 ô lưới như 33 đặc trưng **không có cấu trúc** (mô hình không biết ô nào cùng môn, ô nào cùng năm); chú ý không đương nhiên là lời giải thích (Jain & Wallace [20]).

Cách hoạt động trên dữ liệu của mình

78 token nhúng tuyến tính 32 chiều + [CLS]; 2 khối encoder, 4 đầu chú ý, FFN 64, pre-norm, GELU, dropout 0,1; đầu ra đa nhiệm từ [CLS]. Kết quả: RMSE 0,655 ± 0,027, MAE 0,493, R^2 0,808, Macro-F1 0,782, PICP 0,923. Hạng 8/10. Đây là đối chứng trực tiếp nhất cho khung đề xuất (cùng là Transformer, khác ở chỗ không biết cấu trúc môn × học kỳ): **XEdu-KANFormer tốt hơn FT-Transformer có ý nghĩa thống kê** (MAE 0,481 so với 0,492, Wilcoxon p = 0,028).

2.7. TabPFN – mô hình nền tảng cho dữ liệu bảng

Nó là gì, dùng để làm gì

TabPFN (Hollmann và cs., *Nature* 2025 [7]) là một Transformer **đã được huấn luyện trước** trên hàng triệu bộ dữ liệu tổng hợp sinh từ mô hình nhân quả có cấu trúc. Khi dùng, nó **không huấn luyện lại**: toàn bộ tập huấn luyện được đưa vào làm "ngữ cảnh", và mô hình suy ra dự đoán cho mẫu mới bằng học trong ngữ cảnh (in-context learning), giống cách một LLM đọc ví

dụ rồi trả lời. Nó được thiết kế riêng cho bộ dữ liệu nhỏ (dưới vài nghìn mẫu) – đúng quy mô của mình.

Ưu điểm và nhược điểm

- **Ưu:** độ chính xác rất cao trên dữ liệu nhỏ, gần như không cần chỉnh siêu tham số; xấp xỉ suy luận Bayes nên tự nhiên có độ bất định; không quá khớp theo nghĩa thông thường vì không cập nhật trọng số.
- **Nhược:** hộp đen hoàn toàn và **không sửa được kiến trúc** (không thể cắm KAN, trục thời gian, đầu ra đa nhiệm); mỗi môn cần một lần suy luận riêng (8 lần); tệp mô hình nặng (446 MB khi lưu kèm ngữ cảnh); phiên bản mới nhất yêu cầu đăng ký tài khoản (luận văn dùng bản v2 trọng số mở); chi phí suy luận tăng theo kích thước ngữ cảnh; không thể truy ngược "ô điểm nào kéo kết quả xuống" ngoài các phép thử che hậu nghiệm.

Cách hoạt động trên dữ liệu của mình

Bản TabPFN v2 (gói `tabpfn 2.0.9`), chạy GPU, cấu hình đầy đủ (8 bộ ước lượng tổ hợp); 155 cột đầu vào; 8 bộ hồi quy (mỗi môn một bộ, cùng ngữ cảnh khoảng 1.050 cửa sổ) + 1 bộ phân loại. Kết quả: **RMSE 0,444 ± 0,035 – tốt nhất, tách biệt hẳn** (hạng trung bình 1,14), MAE 0,331, R^2 0,912, Macro-F1 0,812, PICP 0,919, MPIW 1,49 (khoảng hẹp nhất). RMSE riêng 3 môn thi 0,440. Thời gian 57,3 giây mỗi lần vì phải suy luận 9 lần. Khoảng cách với mô hình thứ hai (0,11 điểm) cho thấy lợi thế của tiền huấn luyện trên dữ liệu tổng hợp khi bộ dữ liệu thật chỉ có vài trăm học sinh.

2.8. TabKANet – nhúng đặc trưng bằng KAN + Transformer

Nó là gì, dùng để làm gì

Mạng Kolmogorov–Arnold (KAN, Liu và cs. [8]) thay trọng số tuyến tính cố định trên cạnh bằng **hàm một biến học được** (B-spline). TabKANet (Gao và cs. [36]) dùng ý tưởng đó ở bước nhúng: mỗi đặc trưng số x được biến thành vector token qua một hàm spline $\varphi(x)$ thay vì phép nhân tuyến tính $x \cdot w$, rồi mới đưa vào Transformer chuẩn. Mục đích: cho phép mỗi môn có một "đường cong" phi tuyến riêng (ví dụ Toán 5→6 quan trọng hơn Toán 9→10), và đường cong này vẽ ra được.

Ưu điểm và nhược điểm

- **Ưu:** nhúng phi tuyến, diễn giải được bằng cách vẽ $\varphi(x)$ của từng môn; giữ nguyên ưu điểm của Transformer phía sau.
- **Nhược:** thêm tham số (mỗi môn 8 hệ số spline × 32 chiều); spline có lưới cố định nên giá trị ngoài khoảng chuẩn hóa chỉ còn phần cơ sở SiLU; vẫn không có cấu trúc môn × năm; chưa có công trình áp dụng cho điểm số phổ thông.

Cách hoạt động trên dữ liệu của mình

Giống FT-Transformer ở mục 2.6 nhưng token hóa bằng KAN (B-spline bậc 3, 5 đoạn lưới trên khoảng [−3, 3] của giá trị chuẩn hóa). Kết quả: RMSE 0,622 ± 0,029, MAE 0,465, R^2 0,826, Macro-F1 0,790, PICP 0,924. Hạng 4/10, tốt hơn FT-Transformer (0,655) rõ rệt → **token hóa KAN có giúp** khi gắn vào Transformer chuẩn; đồng thời tốt hơn khung đề xuất có ý nghĩa ($p < 0,001$).

2.9. Kanformer – chú ý đa đầu + lớp KAN

Nó là gì, dùng để làm gì

Kanformer (Alnasyan và cs. [21]) là mô hình giáo dục đầu tiên ghép chú ý đa đầu với các lớp KAN ở phần dự đoán, đạt 99,21% trên OULAD (học trực tuyến). Ý tưởng: dùng attention để tổng hợp tương tác giữa đặc trưng, rồi dùng KAN (thay cho MLP) ở phần đầu ra để các hàm phi tuyến cuối cùng diễn giải được.

Ưu điểm và nhược điểm

- **Ưu:** kết hợp hai nguồn giải thích (trọng số chú ý + hàm spline đầu ra); nhẹ hơn một Transformer đầy đủ (chỉ một khối chú ý).
- **Nhược:** được thiết kế cho dữ liệu nhật ký học trực tuyến (hàng chục nghìn mẫu, phân loại nhị phân), chưa kiểm chứng trên điểm số phổ thông; gộp trung bình token (mean pooling) làm mất thông tin ô nào quan trọng; không có trục thời gian.

Cách hoạt động trên dữ liệu của mình

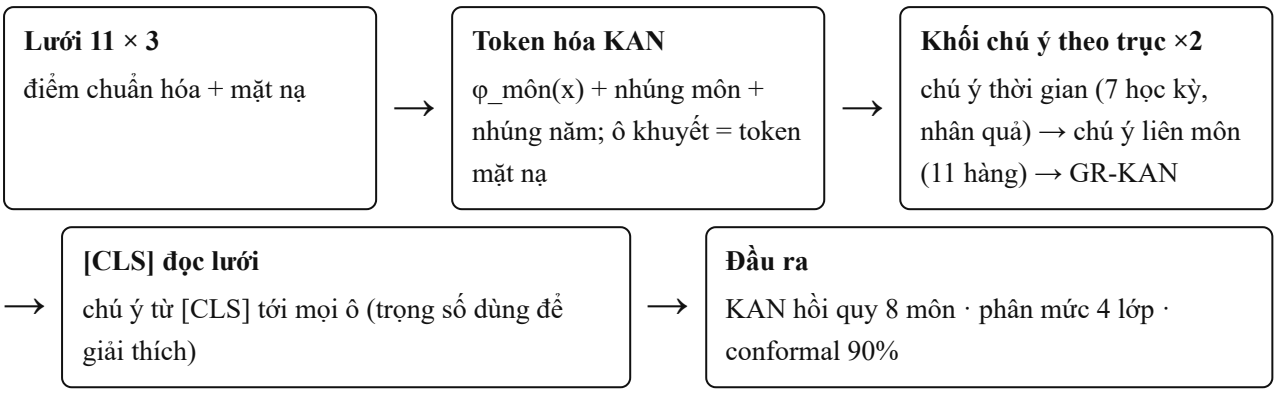
78 token nhúng tuyến tính 32 chiều → một khối chú ý đa đầu (4 đầu) với kết nối tắt và LayerNorm → lấy trung bình token → lớp KAN 32→32 (tanh) → đầu hồi quy bằng KAN (32→8) và đầu phân mức tuyến tính. Kết quả: RMSE 0,627 ± 0,030, MAE 0,471, R^2 0,823, Macro-F1 0,811, PICP 0,919. Hạng 5/10. Lớp KAN ở **đầu ra** tiếp tục cho kết quả tốt, xác nhận hướng kết hợp chú ý + KAN mà luận văn chọn.

2.10. XEdu-KANFormer – khung đề xuất

Nó là gì, dùng để làm gì

XEdu-KANFormer (eXplainable Education KAN-Transformer) là khung do luận văn đề xuất, thiết kế để trả lời cùng lúc bốn câu hỏi của giáo viên: (1) điểm lớp 9 dự kiến bao nhiêu, (2) vì sao, (3) cần làm gì, (4) tin cậy đến đâu. Nó ghép bốn thành phần: **token hóa KAN** (hàm spline riêng cho từng môn, dùng chung qua các năm), **Transformer chú ý theo trục** trên lưới môn × năm (chú ý theo thời gian với mặt nạ nhân quả, rồi chú ý liên môn trong cùng năm), **GR-KAN** thay mạng truyền thẳng (kích hoạt hữu tỉ theo nhóm, theo KAT [9]), và **đầu ra đa nhiệm** (hồi

quy 8 môn bằng KAN + phân mức). Bên ngoài mô hình là mô-đun conformal và tầng giải thích năm mức.



Ưu điểm và nhược điểm

- **Ưu (theo thiết kế):** là mô hình duy nhất trong mười mô hình **biết cấu trúc dữ liệu** – nó phân biệt "cùng môn khác năm" với "cùng năm khác môn"; mặt nạ nhân quả bảo đảm không nhìn trước tương lai; hàm φ_môn vẽ ra được (diễn giải nội tại); trọng số chú ý [CLS] → ô lưới cho bản đồ "ô nào kéo kết quả"; một mạng ra cả điểm lẫn mức; sẵn sàng cho T = 7 học kỳ khi có sổ điểm học kỳ mà không đổi kiến trúc.
- **Nhược (theo thực nghiệm):** nhiều thành phần và nhiều siêu tham số; huấn luyện chậm hơn MLP khoảng 12 lần (22 giây/lần); trọng số đa nhiệm λ = 0,3 đang làm đầu hồi quy kém đi rõ rệt (xem bảng loại bỏ thành phần); các thành phần KAN (token hóa, GR-KAN) chưa cho lợi ích đo được ở quy mô 1.531 cửa sổ.

Cách hoạt động trên dữ liệu của mình

d = 32, 4 đầu chú ý, 2 khối, dropout 0,1; lưới 11 × 7 học kỳ với mặt nạ nhân quả trên trục thời gian; mất mát Huber (8 môn) + 0,3 × entropy chéo (mức); AdamW $2 \cdot 10^{-3}$, dừng sớm. Kết quả: RMSE 0,634 ± 0,032, MAE 0,480, R^2 0,820, Macro-F1 0,795, PICP 0,925, MPIW 2,14; RMSE 3 môn thi 0,720. **Hạng 6/10** (hạng trung bình 5,97; trước đây hạng 7/10 khi chỉ có 3 mốc cả năm). Khung đề xuất **tốt hơn có ý nghĩa** so với FT-Transformer (p = 0,028) và hồi quy tuyến tính (p = 0,005), **ngang** Bi-LSTM và TabNet, **còn kém** TabPFN, XGBoost, MLP, TabKANet, Kanformer. Kết quả loại bỏ thành phần bên dưới chỉ rõ thành phần nào đang giúp và thành phần nào đang kéo lùi.

Biến thể loại bỏ thành phần	RMSE	ΔRMSE so với đầy đủ	Ý nghĩa
Bỏ đa nhiệm (chỉ hồi quy)	**0,570 ± 0,040**	−0,063	Cải thiện lớn nhất: đầu phân mức với λ = 0,3 đang kéo đầu hồi quy; biến thể này đứng thứ 3 nếu xếp chung với 10 mô hình (sau TabPFN, XGBoost; vượt MLP)

GR-KAN → MLP	0,614 ± 0,042	−0,019	GR-KAN chưa hơn mạng truyền thẳng thông thường ở quy mô này
Bỏ token hóa KAN (nhúng tuyến tính)	0,624 ± 0,042	−0,009	Spline đầu vào gần như không ảnh hưởng (chênh lệch nhỏ hơn độ lệch chuẩn)
Đầy đủ	**0,634 ± 0,032**	0	Mốc so sánh
Cấu hình nhỏ (d = 16, 1 khối, dropout 0,2)	0,635 ± 0,044	+0,002	Thu nhỏ không giúp – mô hình đầy đủ không bị dư dung lượng
Bỏ chú ý liên môn	0,646 ± 0,042	**+0,012**	**Sai số tăng**: chú ý liên môn (trục môn học) có đóng góp thật – bằng chứng cho giả thuyết cấu trúc môn × học kỳ

Chú ý: ngoài biến thể bỏ đa nhiệm (−0,063, lớn hơn độ lệch chuẩn ≈ 0,04), các chênh lệch còn lại nhỏ hơn độ lệch chuẩn giữa các lần chạy nên là *dấu hiệu*, cần kiểm định thêm. So với lần chạy chỉ có điểm cả năm (khi đó bỏ bất kỳ thành phần nào cũng không làm xấu đi), với 7 học kỳ thành phần chú ý liên môn đã bắt đầu có ích.

3. Bảng kết quả tổng hợp và kiểm định thống kê

#	Mô hình	RMSE	MAE	R^2	Macro-F1	PICP	MPIW	RMSE 3 môn thi	Hạng TB	Giây/lần
1	TabPFN	0,444 ± 0,035	0,331	0,912	0,812	0,919	1,49	0,440	1,14	57,3
2	XGBoost (tham chiếu)	0,552 ± 0,040	0,412	0,863	0,788	0,917	1,83	0,595	3,23	2,3
3	MLP	0,605 ± 0,045	0,452	0,836	0,810	0,924	2,02	0,704	4,30	1,9
4	TabKANet	0,622 ± 0,029	0,465	0,826	0,790	0,924	2,06	0,731	5,04	5,5
5	Kanformer	0,627 ± 0,030	0,471	0,823	0,811	0,919	2,06	0,727	5,66	357,5*
6	**XEdu-KANFormer (đề xuất)**	**0,634 ± 0,032**	0,480	0,820	0,795	0,925	2,14	0,720	5,97	22,0
7	Bi-LSTM	0,644 ± 0,033	0,488	0,814	0,811	0,923	2,17	0,736	7,02	4,2
8	FT-Transformer	0,655 ± 0,027	0,493	0,808	0,782	0,923	2,16	0,777	6,95	3,8
9	TabNet	0,671 ± 0,094	0,487	0,792	0,745	0,927	2,20	0,770	7,03	74,9
10	Hồi quy tuyến tính (tham chiếu)	0,700 ± 0,054	0,528	0,781	0,772	0,919	2,24	0,786	8,65	0,1

Dữ liệu 7 học kỳ, trung bình 8 môn, 15 lần chạy. *Thời gian của Kanformer bị kéo dài do chạy đồng thời với tiến trình khác trên GPU; không dùng để so sánh tốc độ.

Friedman trên 120 khối: $\chi^2 = 559{,}11$, $p \approx 10^{-114}$ → các mô hình khác nhau có ý nghĩa. **Khoảng cách tới hạn Nemenyi** ($\alpha = 0{,}05$) = 1,24. Đọc theo hạng trung bình: TabPFN đứng riêng (1,14); XGBoost và MLP ở nhóm kế tiếp (3,23 – 4,30); TabKANet, Kanformer và XEdu-KANFormer nằm cùng một nhóm, cách nhau dưới khoảng tới hạn (5,04 – 5,97); FT-Transformer, Bi-LSTM, TabNet (6,95 – 7,03); hồi quy tuyến tính cuối cùng (8,65). **Wilcoxon** theo học sinh: khung đề xuất tốt hơn FT-Transformer ($p = 0{,}028$) và hồi quy tuyến tính ($p =$

0,005); ngang Bi-LSTM (p = 0,49) và TabNet (p = 0,60); kém Kanformer, TabKANet, MLP, XGBoost, TabPFN (p < 0,001).

Độ phủ khoảng dự đoán: cả 10 mô hình đạt PICP 0,917 – 0,927 với mục tiêu 0,90, tức là split conformal giữ đúng bảo đảm thống kê bất kể mô hình nền; độ rộng khoảng hẹp dần theo độ chính xác (TabPFN 1,49 → hồi quy tuyến tính 2,24).

So với khi chỉ có sổ cả năm (3 mốc)	RMSE · 3 mốc cả năm	RMSE · 7 học kỳ	Hạng (3 mốc → 7 học kỳ)
TabPFN	0,626	0,444	1 → 1
XGBoost	0,692	0,552	8 → 2
MLP	0,635	0,605	2 → 3
XEdu-KANFormer	0,689	0,634	7 → 6
FT-Transformer	0,683	0,655	6 → 8

4. Phương pháp luận: lập luận dẫn đến thuật toán được chọn

Phần này viết theo cách trình bày trước hội đồng: đi từ yêu cầu của bài toán, qua từng họ thuật toán, chỉ ra mỗi họ giải quyết được gì và còn thiếu gì, để người nghe tự thấy vì sao khung đề xuất có dạng như vậy – rồi đối chiếu trung thực với số liệu.

4.1. Bắt đầu từ yêu cầu, không bắt đầu từ thuật toán

Một công cụ hỗ trợ giáo viên lớp 9 phải trả lời bốn câu hỏi (mục 1.2 của đề cương): **Q1** dự kiến kết quả cả năm bao nhiêu; **Q2** vì sao; **Q3** cần làm gì (môn nào, tăng bao nhiêu); **Q4** tin cậy đến mức nào – và phải trả lời được ngay khi vừa kết thúc học kỳ I lớp 9. Từ đó rút ra năm yêu cầu kỹ thuật:

R1 – Chính xác trên dữ liệu nhỏ	Một khóa, khoảng 500 học sinh, 1.531 cửa sổ; mô hình phải không quá khớp.
R2 – Tôn trọng cấu trúc	Dữ liệu là lưới môn × 7 học kỳ; "Toán HK1 lớp 8" và "Toán HK2 lớp 8" là cùng một chuỗi; các môn trong cùng học kỳ liên hệ nhau.
R3 – Diễn giải nội tại	Rudin [42]: quyết định quan trọng nên dùng mô hình tự giải thích được, không chỉ giải thích hậu nghiệm.
R4 – Độ bất định có bảo đảm	Một con số không đủ để ra quyết định sư phạm; cần khoảng dự đoán có độ phủ kiểm chứng được.
R5 – Đa nhiệm	Cần cả điểm từng môn (để tư vấn) lẫn mức kết quả học tập (để phân luồng), tốt nhất từ một mô hình.

4.2. Đi qua từng họ thuật toán: mỗi bước giải quyết gì, còn thiếu gì

1. **Hồi quy tuyến tính** đáp ứng R3 (hoàn toàn minh bạch) nhưng sai số lớn nhất (RMSE 0,700): quan hệ giữa điểm các học kỳ có phi tuyến và tương tác. → Cần mô hình phi tuyến.
2. **XGBoost** đưa vào phi tuyến và đạt hạng 2 (0,552) – mạnh vì cây chọn nhanh mốc học kỳ I lớp 9. Nhưng nó coi lưới là 155 cột phẳng (phạm R2), mỗi môn một mô hình riêng (phạm R5), giải thích chỉ hậu nghiệm (phạm R3). → Độ chính xác tốt, nhưng không trả lời được Q2, Q3 từ bên trong mô hình.
3. **MLP** (0,605, hạng 3) cho thấy học sâu đơn giản đã rất mạnh. Nhưng nó là hộp đen trải phẳng: không biết R2, không trả lời Q2. → Cần đưa cấu trúc và tính diễn giải vào kiến trúc.
4. **Bi-LSTM** (0,644) đưa "thời gian" vào nhưng ép lưới hai chiều thành chuỗi 78 token. → Chuỗi một chiều là chưa đủ; cần xử lý đồng thời hai trục.

5. **TabNet** (0,671, độ lệch chuẩn 0,094) hứa hẹn diễn giải bằng mặt nạ chọn đặc trưng nhưng bất ổn trên dữ liệu nhỏ. → Diễn giải bằng "chọn cột" không phù hợp khi mọi cột đều có nghĩa.
6. **FT-Transformer** (0,655) cho mọi ô nhìn mọi ô khác – đúng hướng cho tương tác liên môn – nhưng không biết "cùng môn" hay "cùng học kỳ". → Phải tổ chức chú ý theo trục.
7. **TabPFN** (0,444) đặt ra **trần độ chính xác thực tế** của dữ liệu. Nhưng nó là hộp đen không sửa được kiến trúc, không đa nhiệm, không có trục thời gian, không có hàm diễn giải nội tại, tệp mô hình khoảng 450 MB. → Dùng làm thước đo và bộ dự báo tham chiếu, không dùng làm khung giải thích.
8. **TabKANet** (0,622) và **Kanformer** (0,627) cho thấy KAN không làm giảm độ chính xác và thêm được hàm diễn giải nội tại (R3), nhưng vẫn chưa có R2. → Ghép KAN với chú ý theo trục.

4.3. Vì sao chọn XEdu-KANFormer – nó khắc phục điểm yếu nào của ai

Điểm yếu của mô hình trước	XEdu-KANFormer khắc phục bằng	Yêu cầu
Tuyến tính / cây / MLP / FT-Transformer trải phẳng lưới, không biết môn và học kỳ	Nhúng môn + nhúng học kỳ, chú ý *theo trục*: trục thời gian (cùng môn, mặt nạ nhân quả qua 7 học kỳ) rồi trục môn (cùng học kỳ)	R2
Bi-LSTM ép lưới thành chuỗi một chiều	Xử lý hai trục tách biệt, không cần chọn thứ tự duyệt	R2
MLP, FT-Transformer, TabPFN, XGBoost chỉ giải thích hậu nghiệm	Token hóa KAN (hàm φ_môn vẽ được), GR-KAN, trọng số chú ý [CLS] → ô lưới; kết hợp với che ô (occlusion) đã kiểm chứng	R3
Dự đoán chỉ là một con số	Mô-đun split conformal theo từng môn, độ phủ đạt 0,925 (mục tiêu 0,90)	R4
TabNet, TabPFN, XGBoost phải tách hồi quy và phân mức thành hai mô hình	Một mạng, hai đầu ra: mất mát Huber + λ·CE	R5
TabPFN không sửa được, không mở rộng được	Kiến trúc mở: thêm học kỳ, thêm môn, thêm đặc trưng tĩnh mà không đổi thiết kế	Triển khai

XEdu-KANFormer không được chọn vì "Transformer mạnh hơn", mà vì nó là **kiến trúc duy nhất trong mười mô hình thỏa đồng thời R2–R5**. Câu hỏi còn lại là R1: nó trả giá bao nhiêu độ chính xác cho các tính chất đó, và trả giá ở đâu.

4.4. Thực nghiệm nói gì – và nói thế nào cho trung thực

Sự thật cần nói thẳng

Trên dữ liệu 7 học kỳ, khung đề xuất **chưa đạt** mục tiêu MT5 của đề cương (RMSE thấp hơn mô hình cơ sở tốt nhất với $p < 0,05$). Nó xếp hạng 6/10 (RMSE 0,634): tốt hơn có ý nghĩa FT-Transformer và hồi quy tuyến tính, ngang Bi-LSTM và TabNet, kém TabPFN (0,444), XGBoost (0,552), MLP (0,605) và hai mô hình KAN (0,622; 0,627).

Cách lập luận đúng là không che giấu điều đó, mà đặt nó vào bối cảnh và chỉ ra nguyên nhân có bằng chứng:

1. **Dữ liệu học kỳ đúng như giả định của đề cương.** Khi chuyển từ 3 mốc cả năm sang 7 học kỳ, sai số của khung giảm từ 0,689 xuống 0,634 và hạng tăng từ 7 lên 6; mọi mô hình đều cải thiện. Biểu diễn lưới môn × học kỳ là lựa chọn đúng.
2. **Cấu trúc liên môn có đóng góp thật.** Bỏ chú ý theo trục môn học làm sai số tăng (0,646). Đây là bằng chứng trực tiếp cho khoảng trống KT1 mà đề tài nêu: mô hình biết các môn trong cùng học kỳ liên hệ nhau thì dự báo tốt hơn. Đồng thời khung tốt hơn FT-Transformer (cùng là Transformer nhưng không biết cấu trúc) có ý nghĩa thống kê.
3. **Nguyên nhân chính của khoảng cách: trọng số đa nhiệm.** Bỏ đầu phân mức (chỉ giữ hồi quy) đưa RMSE xuống **0,570** – vượt MLP, TabKANet, Kanformer và đứng thứ 3 nếu xếp chung, chỉ sau TabPFN và XGBoost. Nghĩa là kiến trúc lõi không yếu; $\lambda = 0,3$ chọn tay đang làm đầu hồi quy kém đi. Chọn λ trên tập kiểm định, như đề cương đã dự kiến, là bước hoàn thiện đầu tiên.
4. **Thành phần KAN chưa cho lợi ích đo được.** Thay GR-KAN bằng MLP (0,614) hoặc bỏ token hóa KAN (0,624) cho kết quả ngang hoặc hơi tốt hơn; giá trị của KAN trong khung hiện nằm ở *tính diễn giải* (hàm spline vẽ được) chứ chưa ở độ chính xác. Cần nói rõ điều này.
5. **Điều mô hình đề xuất vẫn giữ được.** Độ phủ conformal 0,925 (cao nhất nhóm học sâu, đạt mục tiêu); là mô hình duy nhất xuất bản đồ chú ý trên lưới môn × học kỳ và hàm $\varphi_{môn}$; trả lời đủ Q1–Q4 trong một khung thống nhất đã triển khai thành web app.

4.5. Kết luận lựa chọn và cách phát biểu trước hội đồng

Phát biểu đề nghị

"Luận văn đề xuất XEdu-KANFormer như một *khung* tích hợp dự đoán – giải thích – khuyến nghị – độ bất định, không phải như một mô hình đơn lẻ thi đua về sai số. Trên dữ liệu một khóa học sinh, 7 học kỳ, khung đạt RMSE 0,634, tốt hơn có ý nghĩa Transformer dạng bảng không có cấu trúc (FT-Transformer); độ phủ khoảng dự đoán 0,925 đạt mục tiêu. Phân tích loại bỏ thành phần cho thấy chú ý liên môn có đóng góp, và biến thể chỉ hồi quy đạt RMSE 0,570 – đứng thứ ba sau mô hình nền tảng TabPFN và XGBoost – nên khoảng cách còn lại chủ yếu đến từ trọng số đa nhiệm chưa được chọn tối ưu. Vì vậy hệ thống triển khai dùng **hai mô hình**: TabPFN làm bộ dự đoán tham chiếu về độ chính xác, XEdu-KANFormer làm bộ dự đoán có tầng giải thích; cả hai cùng được bọc conformal và cùng đi qua luật Thông tư 22 và LLM cục bộ để sinh khuyến nghị."

Những câu hỏi hội đồng có thể đặt và cách trả lời ngắn:

- ***"Sao không dùng TabPFN cho xong?"*** – TabPFN không sửa được kiến trúc, không đa nhiệm, không có trục thời gian, không có hàm diễn giải nội tại, nặng khoảng 450 MB và phải suy luận 8 lần cho 8 môn. Nó là thước đo tốt nhất, không phải khung giải thích; hệ thống vẫn dùng nó song song.
- ***"XGBoost đứng thứ hai, sao không dùng XGBoost?"*** – XGBoost mạnh khi có mốc học kỳ I lớp 9 rất gần mục tiêu, nhưng coi 155 cột là phẳng, mỗi môn một mô hình, giải thích chỉ bằng SHAP hậu nghiệm. Đề tài thuộc nhóm học sâu và hướng tới diễn giải nội tại; XGBoost được báo cáo trung thực như mốc tham chiếu.
- ***"Mô hình đề xuất thua MLP thì đóng góp là gì?"*** – (i) cách biểu diễn lưới môn × học kỳ có mặt nạ, đã chứng minh có lợi (mọi mô hình cải thiện khi có học kỳ); (ii) bằng chứng chú ý liên môn có đóng góp; (iii) quy trình đánh giá 15 lần chạy với kiểm định thống kê và conformal cho cả 10 mô hình; (iv) tầng giải thích – khuyến nghị – ngôn ngữ tự nhiên chạy cục bộ đã triển khai thành web app. Biến thể chỉ hồi quy của khung đã vượt MLP (0,570 so với 0,605).
- ***"Kết quả có tổng quát không?"*** – Một trường, một khóa; tất cả kết luận là cho bối cảnh này. Việc chia theo lớp và lặp 3 hạt giống hạn chế rò rỉ và may rủi, nhưng không thay được kiểm chứng ở trường khác.
- ***"Macro-F1 chỉ 0,75–0,81, thấp hay cao?"*** – Mức kết quả học tập là hàm ngưỡng của điểm; sai số nhỏ quanh ngưỡng 6,5 hoặc 8,0 đủ đổi mức, nên Macro-F1 bị giới hạn bởi cùng sai số hồi quy. Khóa này không có mức Chưa đạt nên thực chất là bài toán 3 lớp.

5. Tài liệu tham khảo (đánh số theo đề cương)

6. Y. Gorishniy, I. Rubachev, V. Khrulkov, A. Babenko, “Revisiting deep learning models for tabular data,” NeurIPS 34, 2021.
7. N. Hollmann et al., “Accurate predictions on small data with a tabular foundation model,” *Nature* 637, 2025.
8. Z. Liu et al., “KAN: Kolmogorov–Arnold networks,” ICLR 2025.
9. X. Yang, X. Wang, “Kolmogorov–Arnold Transformer,” ICLR 2025.
12. Y. Huang et al., “Applying machine learning and SHAP method to identify key influences on middle-school students’ mathematics literacy performance,” *Journal of Intelligence* 12(10), 2024.
17. H. Waheed et al., “Early prediction of learners at risk in self-paced education: A neural network approach,” *Expert Systems with Applications* 213, 2023.
18. E. Kalita et al., “Predicting student academic performance using Bi-LSTM,” *Frontiers in Education* 10, 2025.
20. S. Jain, B. C. Wallace, “Attention is not explanation,” NAACL-HLT 2019.
21. B. Alnasyan et al., “Kanformer: An attention-enhanced deep learning model for predicting student performance in virtual learning environments,” *Social Network Analysis and Mining* 15, 2025.
26. T. T. H. Pham et al., “A data-centric MLOps framework for academic prediction with socioeconomic context in Vietnamese high schools,” *SN Computer Science* 7, 2026.
30. Y. Yang et al., “Student academic performance prediction via hypergraph and TabNet,” *Journal of Big Data* 12, 2025.
33. S. Ö. Arik, T. Pfister, “TabNet: Attentive interpretable tabular learning,” AAAI 2021.
34. L. Grinsztajn, E. Oyallon, G. Varoquaux, “Why do tree-based models still outperform deep learning on typical tabular data?,” NeurIPS 2022.
36. W. Gao et al., “TabKANet: Tabular data modeling with Kolmogorov–Arnold Network and Transformer,” arXiv:2409.08806, 2024.
37. J. Ho et al., “Axial attention in multidimensional transformers,” arXiv:1912.12180, 2019.
42. C. Rudin, “Stop explaining black box machine learning models for high stakes decisions and use interpretable models instead,” *Nature Machine Intelligence* 1, 2019.
44. A. N. Angelopoulos, S. Bates, “Conformal prediction: A gentle introduction,” *Foundations and Trends in Machine Learning* 16(4), 2023.
47. J. Demšar, “Statistical comparisons of classifiers over multiple data sets,” *JMLR* 7, 2006.

Số liệu trong tài liệu này được sinh từ `reports/metrics_runs.csv`, `summary.csv`, `wilcoxon.csv`, `nemenyi_p.csv`, `stats.json` của dự án; mã nguồn mô hình ở `src/e3m/models.py` và quy trình đánh giá ở `experiments/run_benchmark.py`.